ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N. º 1

Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico 1 del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Fogacho Cuaspa Eduardo Mateo – Usuario de GitHub: edufgch0428
Docente	Christian Suárez
Período académico	2026-B
Fecha de entrega	19 de octubre del 2026
Repositorio (fork)	https://github.com/edufgch0428/IDSD422-lab1-lectura-datos

1. Introducción

La empresa RetailAndina S.A. a través de su equipo de Business Intelligence recibió los reportes de la semana en tres formatos distintos como ventas.csv provenientes de las sucursales, ventas.json de la API de la plataforma de fidelización y ventas.xlsx provenientes del departamento de finanzas. Por lo tanto, se requería confirmar que existe la misma información en cada uno de ellos sin ningún tipo de inconsistencia, siendo importante para mantener un estricto control en los datos que se manejan en la empresa.

2. Objetivos

Objetivo General: Analizar cada reporte en los distintos formatos de la empresa RetailAndina S.A. para verificar que se tiene la misma información en cada uno y calcular los indicadores de la semana.

Objetivos específicos:

1. Importar los diferentes reportes CSV, JSON y Excel hacia Google Colab para el análisis respectivo.
2. Comparar filas, columnas y los tipos de datos existentes en los reportes.
3. Calcular el promedio de las ventas, la sucursal con mayor o menor venta, ticket en promedio y región con mayores ventas.

3. Desarrollo de la práctica.

3.1 Realizar el Fork

A través del comando Fork, creé una copia del repositorio que fue proporcionado por el docente en mi cuenta de GitHub (Suárez, 2026), como se ve en la Figura 1 (Anexo A).

El resultado que obtuve es la creación efectiva de una copia del repositorio del docente hacia mi cuenta con la respectiva data y los cripts para hacer la práctica.

3.2 Preparar el ambiente en Google Colab

Después de tener el fork listo, abrí un cuaderno nuevo en Google Colab y cloné el repositorio con git clone de mi cuenta de GitHub. Para autenticarlo usé un token personal y configuré mi nombre y correo para hacer commits. En esta sección tuve inconvenientes con el token, pues, no reconocía el repositorio y tuve que crear otro nuevo token para poder realizar la práctica.

```
usuario = "edufgch0428"     # mi usuario de GitHub
token = getpass("Token: ")  # ingreso el token sin que se muestre
# Descargo mi fork en Colab
!git clone https://{usuario}:{token}@github.com/{usuario}/IDSD422-lab1-lectura-datos.git
# Entro a la carpeta para que las rutas funcionen
%cd IDSD422-lab1-lectura-datos
```

Finalmente, tuve como resultado una clonación exitosa con las carpetas de data y scripts en el panel de la parte izquierda como en la Figura 2 (Anexo A) y quedó todo listo para poder realizar la práctica en base a las instrucciones que se pide.

3.3 Lectura de los tres reportes en Python

Después de una clonación exitosa, ejecuté los scripts en Colab para la lectura de ventas.csv, ventas.json y ventas.xlsx (pandas development team, 2026). Posterior a ello hice commits para subir los cambios.

3.3.1 Ventas.csv

Con ayuda de la librería pandas leí el reporte para revisar sus dimensiones y la tabla en conjunto con los tipos de datos como se muestra en la Figura 3 (Anexo A).

```
ventas = pd.read_csv("data/ventas.csv")
print("Dimensiones: \n", ventas.shape) #Imprimir dimensiones
print(ventas.head()) #Imprimir head
```

3.3.2 Ventas.json

Leí el archivo con json.load que lo carga como una estructura de Python (Python Software Foundation, 2026) y aplané la información con json_normalize para obtener una tabla que se indica en la Figura 4 (Anexo A).

```
with open("data/ventas.json", encoding="utf-8") as f: ##Abrir archivos de JSON
datos = json.load(f)
ventas = pd.json_normalize(datos)
print(ventas.head()) #Imprimir tabla
print("Dimensiones: ", ventas.shape) #Imprimir dimensiones
```

3.3.3 Ventas.xlsx

Leí el archivo con read_excel y de esta manera, con ayuda de pandas, tuve un DataFrame que se muestra en la Figura 5 (Anexo A).

```
ventas = pd.read_excel("data/ventas.xlsx")
print("Dimensiones: ", ventas.shape) #Imprimir las dimensiones
print(ventas.head()) #Imprimir la tabla
```

Finalmente tuve la conversión de todas las tablas con sus respectivos reportes en un DataFrame y de esta manera comprobé que en efecto la información coincidía en cada una y no existía inconsistencias debido a que todas presentaban la misma información.

3.4 Realizar cálculos

Con un script, completé y ejecuté en Google Colab los diferentes cálculos de los indicadores como ventas promedio por sucursal, ticket en promedio, sucursal con mayor y menor venta y región con mayor venta y finalmente subí el commit al fork de mi cuenta en GitHub. La ejecución completa se visualiza en la Figura 6 (Anexo A).

```
print(ventas.groupby("sucursal")["ventas"].mean()) ##1. Venta promedio por sucursal
##2. Ticket promedios
print("El promeido de tickets es: ", ventas["ventas"].sum() / ventas["clientes"].sum())
```

```
print("Sucursal con mayor venta es: ",
   ventas.loc[ventas["ventas"].idxmax(), "sucursal"]) ## 3. Sucursal  con mayor venta y menor venta
print("Sucursal con menor venta es: ",
   ventas.loc[ventas["ventas"].idxmin(), "sucursal"])
ventas_por_region = ventas.groupby("region").sum("ventas")
print()
ventas_por_region = ventas.groupby("region")[["ventas"]].sum().reset_index()
print(ventas_por_region) ## 4. Mayor región que tiene ventas
print("La region con mas ventas es:", ventas_por_region.loc[ventas_por_region["ventas"].idxmax(),
"region"]) ## 4.1. Imprimir la region que tiene mas ventas
```

El resultado que obtuve al ejecutar el script fueron el promedio de tickets exacto (38.07), la sucursal con mayor venta que es Guayaquil Centro(15200), la sucursal con menor venta que es Cuenca (8540) y la región que más ventas tuvo que es la Sierra (30860). Estos resultados obtuve después de trabajar detalladamente con los datos proporcionados.

3.5 Completa el informe respondiendo las 5 preguntas, con el código y sus salidas como respaldo:

- ¿Cuántas filas y columnas tiene la tabla en cada uno de los tres formatos?

De acuerdo con las figuras 3,4,5; las filas y columnas de cada formato o reporte es de (5,4) respectivamente con la información de sucursal, región, ventas y clientes.

¿Fue igual en los tres? ¿Por qué?

Por supuesto que fue igual en cada uno, esto se debe porque solo había un formato diferente en cada reporte más no un contenido distinto en los mismos.

- ¿Qué tipo de datos se infirió para ventas y clientes? ¿Qué indicaría que

salieran como texto?

De acuerdo con los datos de cada columna, se infirió que ventas y clientes eran de tipo int(64) por los valores que existen en ellas según la figura 3. Si salieran como texto, Indicaría que existe alguna inconsistencia en los datos en alguna de las celdas. Por lo tanto, tocaría hacer una limpieza para poder realizar cualquier tipo de cálculo.

- En Python, ¿qué estructura devuelve json.load y por qué hay que "aplanarla"?

La estructura que devuelve json.load es un diccionario (clave-valor), por lo tanto, hay que aplanar ese diccionario para transformarlo en un DataFrame como en la figura 4. De esta manera, se usa la función json_normalize para cumplir con este requerimiento.

- ¿Para qué sirve indicar sheet_name/sheet al leer Excel?

Usar sheet_name ayuda a leer con exactitud la hoja de Excel que se requiere o se necesita como en la figura 5, pues, si no se lo especifica, pandas lee por defecto la primera hoja y aquello nos puede ocasionar errores si trabajamos con datos equivocados

- ¿Qué diferencia ves entre leer en Python y leer en R (conceptos, no sintaxis)?

Al leer el DataFrame en Python, se puede notar que se necesita usar una función llamada dtypes para verificar los tipos de datos que se encuentran en el DataFrame como en la figura 3, mientras que, en R, al momento de mostrar directamente la tabla aparece los tipos de datos usados sin necesidad de usar alguna función adicional.

4. ¿Qué aprendí con esta práctica?

Lo que aprendí en esta práctica fue la transformación de archivos de diferentes tipos como lo son CSV, JSON y Excel, hacia un DataFrame. De esta manera pude manipular cada uno de los documentos de igual forma. A su vez, entendí cómo se estructura una CSV que se lee directo por ser un texto plano, un JSON que siempre hay que aplanarlo porque viene con diccionarios y un Excel que puede tener varias hojas y siempre hay que especificar en qué hoja se quiere trabajar. Entre lo más difícil fue entender cómo se ejecutan las funciones .groupby y .loc en conjunto con el funcionamiento de cada uno. Esto lo resolví buscando exactamente el trabajo que cumple ambas funciones para entender mucho mejor la lógica que existe detrás de las mismas y a su vez, poder resolver de mejor manera los cálculos requeridos. Para la próxima vez trataré de dar un commit en cada cambio que haga en el código

5. Conclusiones
    1. Logré leer todos los reportes de la práctica a través de Google Colab, que, con ayuda de pandas, se lo transformó a un DataFrame de acuerdo con las figuras 3, 4 y 5 dónde los formatos CSV y Excel se leyeron directamente mientras que, el formato JSON tuve que aplanarlo para poder leerlo.
    2. Comparé las distintas filas y columnas de cada reporte con sus respectivos datos para descartar posibles anomalías o inconsistencias gracias a los scripts usados en las figuras 3, 4 y 5, concluyendo que todas las tablas tienen dimensiones de (5,4).
    3. Calculé el ticket promedio de la semana, el promedio de las ventas de cada sucursal, sucursal con mayor y menor ventas junto con la región con mayores ventas. Concluyendo que el ticket promedio fue 38.07, el promedio de ventas de cada sucursal, la sucursal que mayores ventas tiene es Guayaquil Centro y la que menor ventas tiene fue Cuenca, por otro lado, la región con mayores ventas fue la Sierra (30860). Todos estos resultados se evidencian en la figura 6.

Respuesta a la gerencia: Una vez que analicé cada uno de los reportes, se puede concluir que la información con la cual RetailAndina S.A. trabaja contienen la misma estructura y los mismos datos, por lo que se podría usar cualquiera sin ningún problema, así mismo la sucursal que lidera en ventas es Guayaquil Centro pero a su vez, la región con mayores ventas es la Sierra.

Alcance: Este análisis es solamente de una semana en el cuál es válida solamente para el estudio del comportamiento de las cinco sucursales presentadas.

6. Bibliografía

Pandas development team. (2026). pandas documentation. https://pandas.pydata.org/docs/

Python Software Foundation. (2026). *json — JSON encoder and decoder*. https://docs.python.org/3/library/json.html

Suárez, C. (2026). IDSD422-lab1-lectura-datos [Repositorio de GitHub]. GitHub. https://github.com/christian-suarez1979/IDSD422-lab1-lectura-datos

Declaración del uso de la IA.

En el respectivo laboratorio se usó la IA a través de Google Gemini para la consulta, el análisis y la redacción del código usado para clonar el repositorio desde mi cuenta de GitHub hacia Google Colab resolviendo problemas del token, las rutas, etc.

7. Anexos

Anexo A. Capturas de pantalla

Capturas crudas donde indico el uso de GitHub en conjunto con Google Colab en el cual, cada imagen indica el código usado y su respectiva salida.

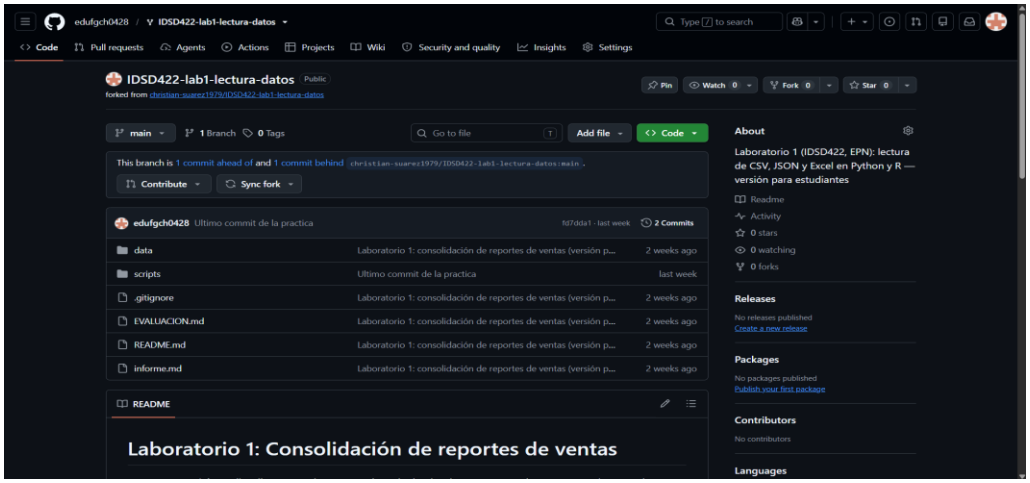


Figura 1. Creación efectiva de la copia en mi GitHub a través del Fork.

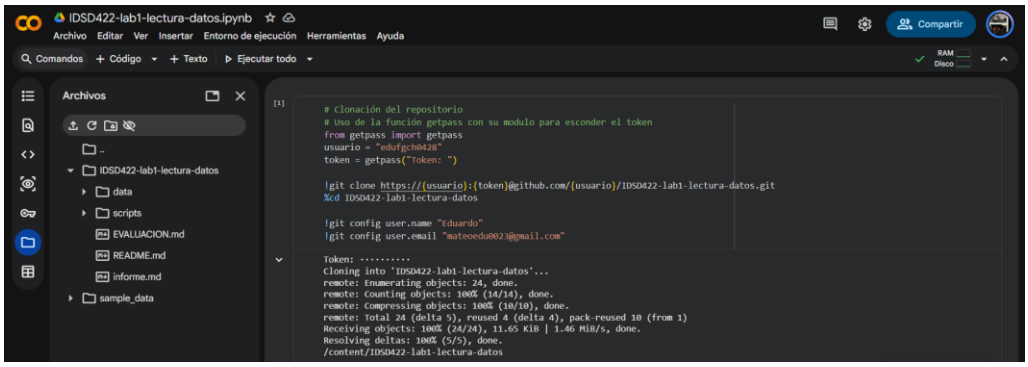


Figura 2. Clonación de mi repositorio en Google Colab con sus respectivas carpetas de data y scripts en el tablero izquierdo.

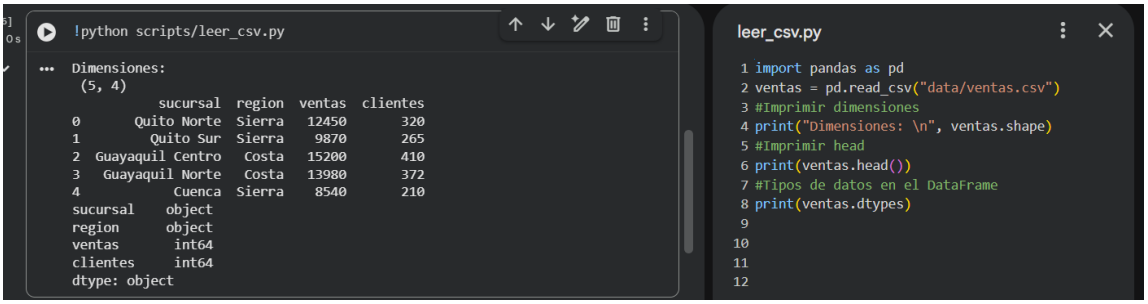


Figura 3. Lectura del CSV en Python con dimensiones (5,4), filas y sus columnas

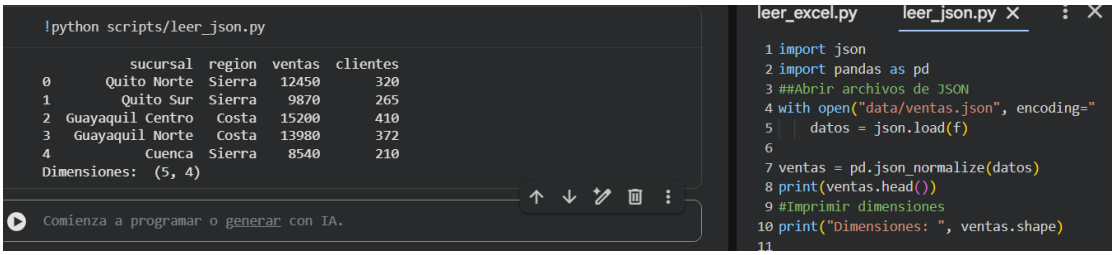


Figura 4. Lectura del JSON en Python con dimensiones (5,4) aplanando la información.



```
!python scripts/leer_excel.py

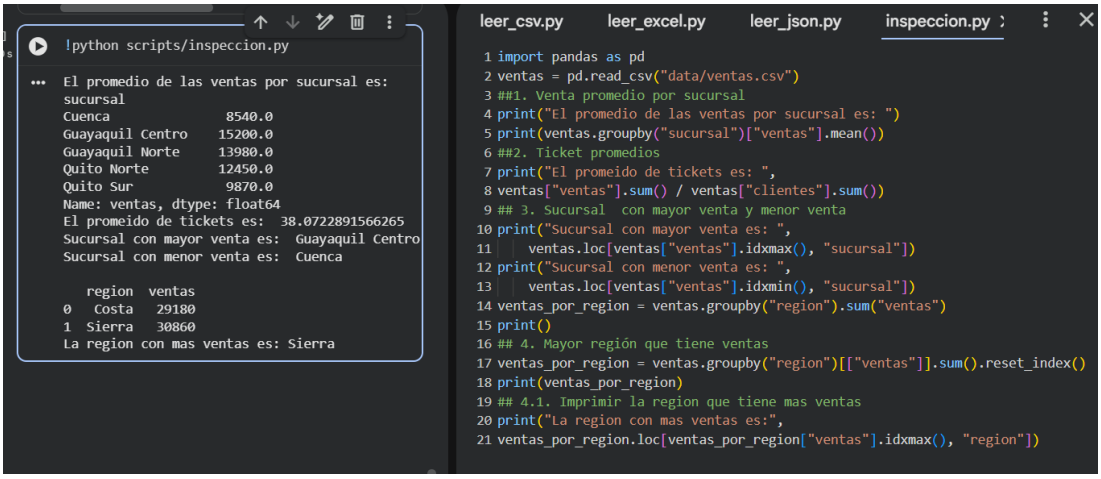
Dimensiones:  (5, 4)

          sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4           Cuenca  Sierra    8540       210
```

```
leer_csv.py  leer_excel.py  leer_json.py  inspeccion.py

import pandas as pd
ventas = pd.read_excel("data/ventas.xlsx", sheet_name="ventas")
#Imprimir las dimensiones
print("Dimensiones: ", ventas.shape)
print()
#Imprimir la tabla
print(ventas.head())
```

Figura 5. Lectura del Excel en Python con sus dimensiones (5,4), filas y columnas



```
!python scripts/inspeccion.py

El promedio de las ventas por sucursal es:
sucursal
Cuenca              8540.0
Guayaquil Centro   15200.0
Guayaquil Norte    13980.0
Quito Norte        12450.0
Quito Sur           9870.0
Name: ventas, dtype: float64
El promeido de tickets es:  38.0722891566265
Sucursal con mayor venta es:  Guayaquil Centro
Sucursal con menor venta es:  Cuenca

   region  ventas
0   Costa   29180
1  Sierra   30860
La region con mas ventas es: Sierra
```

```
leer_csv.py  leer_excel.py  leer_json.py  inspeccion.py

import pandas as pd
ventas = pd.read_csv("data/ventas.csv")
##1. Venta promedio por sucursal
print("El promedio de las ventas por sucursal es: ")
print(ventas.groupby("sucursal")["ventas"].mean())
##2. Ticket promedios
print("El promeido de tickets es: ",
ventas["ventas"].sum() / ventas["clientes"].sum())
## 3. Sucursal  con mayor venta y menor venta
print("Sucursal con mayor venta es: ",
    ventas.loc[ventas["ventas"].idxmax(), "sucursal"])
print("Sucursal con menor venta es: ",
    ventas.loc[ventas["ventas"].idxmin(), "sucursal"])
ventas_por_region = ventas.groupby("region").sum("ventas")
print()
## 4. Mayor región que tiene ventas
ventas_por_region = ventas.groupby("region")[["ventas"]].sum().reset_index()
print(ventas_por_region)
## 4.1. Imprimir la region que tiene mas ventas
print("La region con mas ventas es:",
ventas_por_region.loc[ventas_por_region["ventas"].idxmax(), "region"])
```

Figura 6. Ejecución de inspección.py que muestra los diferentes cálculos requeridos.